

データ解析

サンプルサイズ設計2



創域理工学部

Faculty of Science and Technology

東京理科大学
創域理工学部情報計算科学科
安藤宗司

2023年12月21日

Contents

□ 母比率の差に関する2標本検定問題

- Unconditional approach
- Conditional approach

□ サンプルサイズ設計法

- Unconditional approach
- Conditional approach

諸前提

- 試験治療 T と対照治療 C の応答変数の母比率の差に関する両側検定を考える
 - 試験治療 T の応答変数 $X_i \underset{\text{i.i.d}}{\sim} B(\pi_1, 1)$ ($i = 1, 2, \dots, n$)
 - 対照治療 C の応答変数 $Y_j \underset{\text{i.i.d}}{\sim} B(\pi_2, 1)$ ($j = 1, 2, \dots, m$)

- 母比率が大きいことが臨床的に望ましい状態とする
 - $\varepsilon = \pi_1 - \pi_2 > 0$ が臨床的に望ましい

母比率の差に関する2標本検定

□ 試験治療の対照治療に対する優越性を検証

□ 仮説

■ 帰無仮説 $H_0: \varepsilon = 0$

■ 対立仮説 $H_1: \varepsilon \neq 0$

□ 応答変数の標本平均

$$\bar{\pi}_1 = \frac{1}{n} \sum_{i=1}^n X_i, \quad \bar{\pi}_2 = \frac{1}{m} \sum_{j=1}^m Y_j$$

□ 割付比

■ 各群の参加者数の比を $r = m/n$ とし, $\kappa = r/(r + 1)$ とする

相似検定

帰無仮説	複合仮説	対立仮説	複合仮説
$H_0: \theta \in \Theta_0$		$H_1: \theta \in \Theta_1 = \Theta \cup \Theta_0^c$	
			$\Theta = \Theta_0 \cup \Theta_0^c$ かつ $\Theta_0 \cap \Theta_0^c = \phi$

すべての $\theta_0 \in \Theta_0$ に対して,

$$\beta_W(\theta_0) = P_{\theta_0}((X_1, X_2, \dots, X_n) \in W) = \alpha$$

を満たす棄却域 W を用いた検定を相似検定 (similar test) という

母比率の差に関する2標本相似検定

□ 母集団1

- パラメータ π_1 のベルヌーイ母集団
- 無作為標本 X_1, X_2, \dots, X_n

□ 母集団2

- パラメータ π_2 のベルヌーイ母集団
- 無作為標本 Y_1, Y_2, \dots, Y_m

□ 仮説

- $H_0: \pi_1 = \pi_2$ vs $H_1: \pi_1 \neq \pi_2$

この統計的仮説検定に対する相似検定を構成する

Unconditional approach (1)

$$X_{i \text{ i.i.d}} \sim B(\pi_1, 1) \quad (i = 1, \dots, n) \qquad \sum_{i=1}^n X_i \sim B(\pi_1, n)$$



$$Y_{j \text{ i.i.d}} \sim B(\pi_2, 1) \quad (j = 1, \dots, m)$$

$$\sum_{j=1}^m Y_j \sim B(\pi_2, m)$$

$$\bar{\pi}_1 = \frac{1}{n} \sum_{i=1}^n X_i \underset{n \rightarrow \infty}{\sim} N\left(\pi_1, \frac{\bar{\pi}_1(1 - \bar{\pi}_1)}{n}\right)$$

$$\bar{\pi}_2 = \frac{1}{m} \sum_{j=1}^m Y_j \underset{m \rightarrow \infty}{\sim} N\left(\pi_2, \frac{\bar{\pi}_2(1 - \bar{\pi}_2)}{m}\right)$$

$$\bar{\pi}_1 \perp \bar{\pi}_2 \text{ であることから } \quad \bar{\pi}_1 - \bar{\pi}_2 \sim N\left(\pi_1 - \pi_2, \frac{\bar{\pi}_1(1 - \bar{\pi}_1)}{n} + \frac{\bar{\pi}_2(1 - \bar{\pi}_2)}{m}\right)$$

Unconditional approach (2)

$H_0: \pi_1 = \pi_2$ のもとで

$$\bar{\pi}_1 - \bar{\pi}_2 \sim N\left(0, \frac{\bar{\pi}_1(1 - \bar{\pi}_1)}{n} + \frac{\bar{\pi}_2(1 - \bar{\pi}_2)}{m}\right), \quad Z \equiv \frac{\bar{\pi}_1 - \bar{\pi}_2}{\sqrt{\frac{\bar{\pi}_1(1 - \bar{\pi}_1)}{n} + \frac{\bar{\pi}_2(1 - \bar{\pi}_2)}{m}}} \sim N(0, 1)$$

$H_1: \pi_1 \neq \pi_2$ のもとで

$$\bar{\pi}_1 - \bar{\pi}_2 \sim N\left(\pi_1 - \pi_2, \frac{\bar{\pi}_1(1 - \bar{\pi}_1)}{n} + \frac{\bar{\pi}_2(1 - \bar{\pi}_2)}{m}\right),$$

$$Z \equiv \frac{\bar{\pi}_1 - \bar{\pi}_2}{\sqrt{\frac{\bar{\pi}_1(1 - \bar{\pi}_1)}{n} + \frac{\bar{\pi}_2(1 - \bar{\pi}_2)}{m}}} \sim N\left(\frac{\pi_1 - \pi_2}{\sqrt{\frac{\bar{\pi}_1(1 - \bar{\pi}_1)}{n} + \frac{\bar{\pi}_2(1 - \bar{\pi}_2)}{m}}}, 1\right)$$

Unconditional approach (3)

棄却域 W を次のようにする。

$$W = \left\{ (x_1, x_2, \dots, x_n; y_1, y_2, \dots, y_m) \mid |Z| > z\left(\frac{\alpha}{2}\right) \right\}$$

$H_0: \pi_1 = \pi_2$ のもとで

$$\beta_W(\mu_1, \mu_2) = P_{\theta_0}((X_1, X_2, \dots, X_n; Y_1, Y_2, \dots, Y_m) \in W) = \alpha$$

第1種の過誤確率

$$\Leftrightarrow \int_{|Z| > z\left(\frac{\alpha}{2}\right)} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{Z^2}{2}\right) dZ = \alpha$$

この棄却域 W に基づく検定は相似検定である

Unconditional approach (4)


$H_1: \pi_1 \neq \pi_2$ のもとで

$$\beta_W(\mu_1, \mu_2) = P_{\theta_1}((X_1, X_2, \dots, X_n; Y_1, Y_2, \dots, Y_m) \in W)$$

検出力

$$\Leftrightarrow \int_{|Z| > z(\frac{\alpha}{2})} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(Z - \frac{\pi_1 - \pi_2}{\sqrt{\frac{\bar{\pi}_1(1 - \bar{\pi}_1)}{n} + \frac{\bar{\pi}_2(1 - \bar{\pi}_2)}{m}}}\right)^2\right) dZ$$

Conditional approach (1)


$$\begin{array}{ll} X_{i \text{ i.i.d}} \sim B(\pi_1, 1) \quad (i = 1, \dots, n) & \sum_{i=1}^n X_i \sim B(\pi_1, n) \\ Y_{j \text{ i.i.d}} \sim B(\pi_2, 1) \quad (i = 1, \dots, m) & \sum_{i=1}^m Y_i \sim B(\pi_2, m) \end{array}$$
$$\bar{\pi} = \frac{\sum_{i=1}^n X_i + \sum_{i=1}^m Y_i}{n + m}$$

$H_0: \pi_1 = \pi_2 (= \pi)$ のもとで

$$\bar{\pi}_1 = \frac{1}{n} \sum_{i=1}^n X_i \underset{n \rightarrow \infty}{\sim} N\left(\pi_1, \frac{\bar{\pi}(1 - \bar{\pi})}{n}\right) \quad \bar{\pi}_2 = \frac{1}{m} \sum_{i=1}^m Y_i \underset{m \rightarrow \infty}{\sim} N\left(\pi_2, \frac{\bar{\pi}(1 - \bar{\pi})}{m}\right)$$

$$\bar{\pi}_1 \perp \bar{\pi}_2 \text{ であることから } \bar{\pi}_1 - \bar{\pi}_2 \sim N\left(\pi_1 - \pi_2, \left(\frac{1}{n} + \frac{1}{m}\right) \bar{\pi}(1 - \bar{\pi})\right)$$

Conditional approach (2)

$H_0: \pi_1 = \pi_2$ ($= \pi$) のもとで

$$\bar{\pi}_1 - \bar{\pi}_2 \sim N\left(0, \left(\frac{1}{n} + \frac{1}{m}\right) \bar{\pi}(1 - \bar{\pi})\right), \quad Z \equiv \frac{\bar{\pi}_1 - \bar{\pi}_2}{\sqrt{\left(\frac{1}{n} + \frac{1}{m}\right) \bar{\pi}(1 - \bar{\pi})}} \sim N(0, 1)$$

$H_1: \pi_1 \neq \pi_2$ のもとで

$$\bar{\pi}_1 - \bar{\pi}_2 \sim N\left(\pi_1 - \pi_2, \frac{\bar{\pi}_1(1 - \bar{\pi}_1)}{n} + \frac{\bar{\pi}_2(1 - \bar{\pi}_2)}{m}\right),$$

$$Z \equiv \frac{\bar{\pi}_1 - \bar{\pi}_2}{\sqrt{\frac{\bar{\pi}_1(1 - \bar{\pi}_1)}{n} + \frac{\bar{\pi}_2(1 - \bar{\pi}_2)}{m}}} \sim N\left(\frac{\pi_1 - \pi_2}{\sqrt{\frac{\bar{\pi}_1(1 - \bar{\pi}_1)}{n} + \frac{\bar{\pi}_2(1 - \bar{\pi}_2)}{m}}}, 1\right)$$

Conditional approach (3)

棄却域 W を次のようにする。

$$W = \left\{ (x_1, x_2, \dots, x_n; y_1, y_2, \dots, y_m) \mid |Z| > z\left(\frac{\alpha}{2}\right) \right\}$$

$H_0: \pi_1 = \pi_2$ のもとで

$$\beta_W(\mu_1, \mu_2) = P_{\theta_0}((X_1, X_2, \dots, X_n; Y_1, Y_2, \dots, Y_m) \in W) = \alpha$$

第1種の過誤確率

$$\Leftrightarrow \int_{|Z| > z\left(\frac{\alpha}{2}\right)} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{Z^2}{2}\right) dZ = \alpha$$

この棄却域 W に基づく検定は相似検定である

Conditional approach (4)

$H_1: \pi_1 \neq \pi_2$ のもとで

$$\beta_W(\mu_1, \mu_2) = P_{\theta_1}((X_1, X_2, \dots, X_n; Y_1, Y_2, \dots, Y_m) \in W)$$

検出力

$$\Leftrightarrow \int_{|Z| > z(\frac{\alpha}{2})} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(Z - \frac{\pi_1 - \pi_2}{\sqrt{\frac{\bar{\pi}_1(1 - \bar{\pi}_1)}{n} + \frac{\bar{\pi}_2(1 - \bar{\pi}_2)}{m}}}\right)^2\right) dZ$$

Unconditional approachの場合

- 次式が成立するときに帰無仮説 H_0 を有意水準 α で棄却

$$\left| \frac{\bar{\pi}_1 - \bar{\pi}_2}{\sqrt{\frac{\bar{\pi}_1(1 - \bar{\pi}_1)}{n} + \frac{\bar{\pi}_2(1 - \bar{\pi}_2)}{m}}} \right| \geq z_{\alpha/2}$$

$z_{\alpha/2}$: 標準正規分布の上側 $\alpha/2\%$ 点

- サンプルサイズ設計（検出力の計算）
 - α, r, π_1, π_2 はある値に固定する

検出力の計算 (1)

$$r = \frac{m}{n} \quad \kappa = \frac{r}{r+1} \quad \frac{1-\kappa}{\kappa} = \frac{1}{r}$$

□ 対立仮説 $H_1: \varepsilon \neq 0$ のもとで、検出力は n の関数になる

$$\begin{aligned} \phi(n) &= P \left(\left| \frac{\bar{\pi}_1 - \bar{\pi}_2}{\sqrt{\frac{\bar{\pi}_1(1-\bar{\pi}_1)}{n} + \frac{\bar{\pi}_2(1-\bar{\pi}_2)}{m}}} \right| \geq z_{\alpha/2} \right) \\ &\approx P \left(\left| \frac{\bar{\pi}_1 - \bar{\pi}_2}{\sigma_1} \right| \geq z_{\alpha/2} \right) \quad \sqrt{\frac{\bar{\pi}_1(1-\bar{\pi}_1)}{n} + \frac{\bar{\pi}_2(1-\bar{\pi}_2)}{m}} \text{ を見積値に置き換える} \\ &= P \left(\frac{\bar{\pi}_1 - \bar{\pi}_2}{\sigma_1} \geq z_{\alpha/2} \right) + P \left(\frac{\bar{\pi}_1 - \bar{\pi}_2}{\sigma_1} \leq -z_{\alpha/2} \right) \quad \sigma_1 = \sqrt{\frac{\pi_1(1-\pi_1)}{n} + \frac{\pi_2(1-\pi_2)}{m}} \\ &= P \left(\frac{\bar{\pi}_1 - \bar{\pi}_2 - \varepsilon}{\sigma_1} \geq z_{\alpha/2} - \frac{\varepsilon}{\sigma_1} \right) + P \left(\frac{\bar{\pi}_1 - \bar{\pi}_2 - \varepsilon}{\sigma_1} \leq -z_{\alpha/2} - \frac{\varepsilon}{\sigma_1} \right) \quad = \sqrt{\frac{\kappa\pi_1(1-\pi_1) + (1-\kappa)\pi_2(1-\pi_2)}{n\kappa}} \end{aligned}$$

検出力の計算 (2)

$\Phi(\cdot)$: 標準正規分布の累積分布関数

□ 対立仮説 $H_1: \varepsilon \neq 0$ のもとで, 検出力は n の関数になる

$$\begin{aligned}\phi(n) &\approx P\left(\frac{\bar{\pi}_1 - \bar{\pi}_2 - \varepsilon}{\sigma_1} \geq z_{\alpha/2} - \frac{\varepsilon}{\sigma_1}\right) + P\left(\frac{\bar{\pi}_1 - \bar{\pi}_2 - \varepsilon}{\sigma_1} \leq -z_{\alpha/2} - \frac{\varepsilon}{\sigma_1}\right) \\&= \left(1 - \Phi\left(z_{\alpha/2} - \frac{\varepsilon}{\sigma_1}\right)\right) + \Phi\left(-z_{\alpha/2} - \frac{\varepsilon}{\sigma_1}\right) \\&= \Phi\left(\frac{\varepsilon}{\sigma_1} - z_{\alpha/2}\right) + \Phi\left(-z_{\alpha/2} - \frac{\varepsilon}{\sigma_1}\right) \\&\approx \Phi\left(\frac{\varepsilon}{\sigma_1} - z_{\alpha/2}\right) \quad \left(\because \frac{\varepsilon}{\sigma_1} \gg 0\right)\end{aligned}$$

サンプルサイズ設計

□ 標準正規分布の上側 $\beta\%$ 点を z_β とする

■ $1 - \beta = \Phi(z_\beta)$

□ 検出力 $1 - \beta$ を満たす n は、次式の解として与えられる

$$\frac{\varepsilon}{\sigma_1} - z_{\alpha/2} = z_\beta \Leftrightarrow \frac{\varepsilon}{\sqrt{\frac{\kappa\pi_1(1-\pi_1) + (1-\kappa)\pi_2(1-\pi_2)}{n\kappa}}} - z_{\alpha/2} = z_\beta$$
$$\Leftrightarrow n = \frac{(z_{\alpha/2} + z_\beta)^2}{\varepsilon^2} \frac{\kappa\pi_1(1-\pi_1) + (1-\kappa)\pi_2(1-\pi_2)}{\kappa} \quad m = rn$$

n に小数点以下の単数が含まれるので、切り上げることで試験に必要な参加者数を得る。

検出力が $1 - \beta$ 以上となる最小の自然数として得られる。

Conditional approachの場合

- 次式が成立するときに帰無仮説 H_0 を有意水準 α で棄却

$H_0: \pi_1 = \pi_2 (= \pi)$ のもとで

$$\left| \frac{\bar{\pi}_1 - \bar{\pi}_2}{\sqrt{\left(\frac{1}{n} + \frac{1}{m}\right) \bar{\pi}(1 - \bar{\pi})}} \right| \geq z_{\alpha/2}$$

$z_{\alpha/2}$: 標準正規分布の上側 $\alpha/2$ % 点

- サンプルサイズ設計（検出力の計算）

- α, r, π_1, π_2 はある値に固定する

検出力の計算 (1)

$$r = \frac{m}{n} \quad \kappa = \frac{r}{r+1} \quad \frac{1-\kappa}{\kappa} = \frac{1}{r}$$

□ 対立仮説 $H_1: \varepsilon \neq 0$ のもとで、検出力は n の関数になる

$$\phi(n) = P \left(\left| \frac{\bar{\pi}_1 - \bar{\pi}_2}{\sqrt{\left(\frac{1}{n} + \frac{1}{m}\right) \bar{\pi}(1 - \bar{\pi})}} \right| \geq z_{\alpha/2} \right)$$

$\bar{\pi}$ を見積値 $\pi = \frac{n\pi_1 + m\pi_2}{n+m}$ に置き換える

$$\frac{1}{n} + \frac{1}{m} = \frac{1}{n} + \frac{1}{nr} = \frac{1}{n} \left(1 + \frac{1}{r} \right)$$

$$\sigma_0^2 = \left(\frac{1}{n} + \frac{1}{m} \right) \pi(1 - \pi) = \frac{1}{n\kappa} \pi(1 - \pi) = \frac{1}{n} \frac{r+1}{r} = \frac{1}{n\kappa}$$

$$\sigma_1^2 = \frac{\pi_1(1 - \pi_1)}{n} + \frac{\pi_2(1 - \pi_2)}{m} = \frac{\kappa\pi_1(1 - \pi_1) + (1 - \kappa)\pi_2(1 - \pi_2)}{n\kappa}$$

検出力の計算 (2)

■ 対立仮説 $H_1: \varepsilon \neq 0$ のもとで, 検出力は n の関数になる

$$\begin{aligned}\phi(n) &= P\left(\left|\frac{\bar{\pi}_1 - \bar{\pi}_2}{\sqrt{\left(\frac{1}{n} + \frac{1}{m}\right)\bar{\pi}(1 - \bar{\pi})}}\right| \geq z_{\alpha/2}\right) \\ &\approx P\left(\left|\frac{\bar{\pi}_1 - \bar{\pi}_2}{\sigma_0}\right| \geq z_{\alpha/2}\right) \\ &= P\left(\frac{\bar{\pi}_1 - \bar{\pi}_2}{\sigma_0} \geq z_{\alpha/2}\right) + P\left(\frac{\bar{\pi}_1 - \bar{\pi}_2}{\sigma_0} \leq -z_{\alpha/2}\right) \\ &= P\left(\frac{\bar{\pi}_1 - \bar{\pi}_2 - \varepsilon}{\sigma_1} \geq z_{\alpha/2} \left(\frac{\sigma_0}{\sigma_1}\right) - \frac{\varepsilon}{\sigma_1}\right) + P\left(\frac{\bar{\pi}_1 - \bar{\pi}_2 - \varepsilon}{\sigma_1} \leq -z_{\alpha/2} \left(\frac{\sigma_0}{\sigma_1}\right) - \frac{\varepsilon}{\sigma_1}\right)\end{aligned}$$

検出力の計算 (3)

$\Phi(\cdot)$: 標準正規分布の累積分布関数

□ 対立仮説 $H_1: \varepsilon \neq 0$ のもとで, 検出力は n の関数になる

$$\begin{aligned}\phi(n) &\approx P\left(\frac{\bar{\pi}_1 - \bar{\pi}_2 - \varepsilon}{\sigma_1} \geq z_{\alpha/2} \left(\frac{\sigma_0}{\sigma_1}\right) - \frac{\varepsilon}{\sigma_1}\right) + P\left(\frac{\bar{\pi}_1 - \bar{\pi}_2 - \varepsilon}{\sigma_1} \leq -z_{\alpha/2} \left(\frac{\sigma_0}{\sigma_1}\right) - \frac{\varepsilon}{\sigma_1}\right) \\&= \left(1 - \Phi\left(z_{\alpha/2} \left(\frac{\sigma_0}{\sigma_1}\right) - \frac{\varepsilon}{\sigma_1}\right)\right) + \Phi\left(-z_{\alpha/2} \left(\frac{\sigma_0}{\sigma_1}\right) - \frac{\varepsilon}{\sigma_1}\right) \\&= \Phi\left(\frac{\varepsilon}{\sigma_1} - z_{\alpha/2} \left(\frac{\sigma_0}{\sigma_1}\right)\right) + \Phi\left(-z_{\alpha/2} \left(\frac{\sigma_0}{\sigma_1}\right) - \frac{\varepsilon}{\sigma_1}\right) \\&\approx \Phi\left(\frac{\varepsilon}{\sigma_1} - z_{\alpha/2} \left(\frac{\sigma_0}{\sigma_1}\right)\right) \quad \left(\because \frac{\varepsilon}{\sigma_1} \gg 0\right)\end{aligned}$$

サンプルサイズ設計

□ 標準正規分布の上側 $\beta\%$ 点を z_β とする

■ $1 - \beta = \Phi(z_\beta)$

□ 検出力 $1 - \beta$ を満たす n は、次式の解として与えられる

$$\frac{\varepsilon}{\sigma_1} - z_{\alpha/2} \left(\frac{\sigma_0}{\sigma_1} \right) = z_\beta$$

$$\Leftrightarrow \frac{\varepsilon}{\sqrt{\frac{\kappa\pi_1(1-\pi_1) + (1-\kappa)\pi_2(1-\pi_2)}{n\kappa}}} - z_{\alpha/2} \sqrt{\frac{\pi(1-\pi)}{\kappa\pi_1(1-\pi_1) + (1-\kappa)\pi_2(1-\pi_2)}} = z_\beta$$

$$\Leftrightarrow n = \frac{1}{\varepsilon^2} \left(z_{\alpha/2} \sqrt{\frac{\pi(1-\pi)}{\kappa}} + z_\beta \sqrt{\frac{\kappa\pi_1(1-\pi_1) + (1-\kappa)\pi_2(1-\pi_2)}{\kappa}} \right)^2 \quad m = rn$$