

# 機械学習（7回目）

創域理工学部 情報計算科学科

桂田 浩一

1

11/2/2023

## 前回の復習

- 複雑な依存関係がある場合（誤差逆伝播法がそのまま適用できない場合）の偏微分の求め方

3


## 本日の内容

- 相互結合型ネットワーク
- ホップフィールドモデル

11/2/2023

4

## ホップフィールドモデル



$w_{j,i}$ は変化せず  $x_i$ が変化する

入力：各ユニットへの0, 1の割り当て

出力：各ユニットの値の更新を繰り返し、更新されなくなった時の値

ユニット  $i$  を選択し、次のように値を更新

$$x_i(t+1) = \begin{cases} 1 & (u_i(t) > 0) \\ x_i(t) & (u_i(t) = 0) \\ 0 & (u_i(t) < 0) \end{cases}$$

$$u_i(t) = \sum_{j=1}^n w_{j,i} x_j(t) - \theta_i$$

( $i$  以外のユニットは値を更新しない)

$$(w_{j,i} = w_{i,j}, w_{i,i} = 0)$$


11/2/2023

5

## ホップフィールドモデルの実行例

入力 :  $x_1(0) = 0, x_2(0) = 1, x_3(0) = 0$

ユニット1, 2, 3の順で繰り返して値を更新



$$\begin{aligned} u_1(0) &= \sum_{j=1}^3 w_{j,1} x_j(0) - \theta_1 \\ &= w_{1,2} x_2(0) + w_{1,3} x_3(0) - \theta_1 \\ &= 1 * 1 + 0 * 0 - 0 = 1 > 0 \end{aligned}$$

$$x_1(1) = 1, x_2(1) = 1, x_3(1) = 0$$

$$\begin{aligned} u_2(1) &= \sum_{j=1}^3 w_{j,2} x_j(1) - \theta_2 \\ &= w_{1,2} x_1(1) + w_{2,3} x_3(1) - \theta_2 \\ &= 1 * 1 + 0.5 * 0 - 1 = 0 \end{aligned}$$

$$x_1(2) = 1, x_2(2) = 1, x_3(2) = 0$$


11/2/2023

6

## ホップフィールドモデルの実行例

入力 :  $x_1(0) = 0, x_2(0) = 1, x_3(0) = 0$

ユニット1, 2, 3の順で繰り返して値を更新



$$\begin{aligned} u_3(2) &= \sum_{j=1}^3 w_{j,3} x_j(2) - \theta_3 \\ &= w_{1,3} x_1(2) + w_{2,3} x_2(2) - \theta_3 \\ &= 0 * 1 + 0.5 * 1 - 0 = 0.5 > 0 \end{aligned}$$

$$x_1(3) = 1, x_2(3) = 1, x_3(3) = 1$$

⋮

$$x_1(6) = 1, x_2(6) = 1, x_3(6) = 1$$

更新が無いのでこれで終了

↑ 平衡状態という

11/2/2023


7

## エネルギー関数

- ネットワークの平衡状態を定義付ける関数

$$E = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n w_{j,i} x_i x_j + \sum_{i=1}^n \theta_i x_i$$

※  $x_i$  を更新する毎に  $E$  の値が減少するという性質がある



11/2/2023

8

## エネルギー関数が減少することの証明

$$\begin{aligned} \blacksquare E &= -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n w_{j,i} x_i x_j + \sum_{i=1}^n \theta_i x_i \\ &= -\frac{1}{2} \sum_{i \neq k} \sum_{j \neq k} w_{j,i} x_i x_j + \sum_{i \neq k} \theta_i x_i \\ &\quad -\frac{1}{2} \sum_j w_{j,k} x_k x_j - \frac{1}{2} \sum_i w_{k,i} x_i x_k + \frac{1}{2} w_{k,k} x_k x_k + \theta_k x_k \end{aligned}$$

- ある時刻  $t$  に  $k$  番目のユニットが  $x_k(t) \rightarrow x_k(t+1)$  と更新されたとする. ( $\Delta x_k = x_k(t+1) - x_k(t)$  と表す)

11/2/2023

9

## エネルギー関数が減少することの証明

■ このときエネルギー関数の変化  $\Delta E_k$  は  $w_{k,k} = 0$

$$\begin{aligned}\Delta E_k &= -\frac{1}{2} \left\{ \sum_j w_{j,k} x_j + \sum_i w_{k,i} x_i \right\} \Delta x_k + \frac{1}{2} w_{k,k} x_k x_k + \theta_k \Delta x_k \\ &= -\left\{ \sum_{j=1}^n \frac{w_{j,k} + w_{k,j}}{2} x_j \right\} \Delta x_k + \theta_k \Delta x_k \\ &= -\left( \sum_{j=1}^n w_{j,k} x_j - \theta_k \right) \Delta x_k \\ &= -u_k \Delta x_k\end{aligned}$$

$\Delta x_k > 0$  のとき  $x_k(t+1) = 1, x_k(t) = 0$  なので  $u_k(t) > 0$

$\Delta x_k < 0$  のとき  $x_k(t+1) = 0, x_k(t) = 1$  なので  $u_k(t) < 0$

どちらの場合も  $-u_k \Delta x_k < 0$  となるので  $\Delta E_k \leq 0$

11/2/2023

10

## ホップフィールドモデルの使い方

### ■ ホップフィールドモデルの特徴：

エネルギー関数を極小化する方向にユニットの値が更新される

⇒ 特定の0, 1のパターンの時にエネルギー関数が極小値となるよう重みを設定すれば、任意の入力に対してそれに近いパターンにユニットの値が修正される。

連想記憶に使える

11/2/2023


11

## 連想記憶

- 不完全なパターン（一部が欠けていたり，ノイズがあるなど）を入力とすると，学習した完全なパターンを出力（想起）するネットワーク

※以下，連想記憶ではユニットの取る値を $(-1,1)$ とする．

格子の交点がユニット，  
辺がノード間のリンク




11/2/2023

12

## 連想記憶を実現するための重み設定

$$E = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n w_{j,i} x_i x_j + \sum_{i=1}^n \theta_i x_i$$

記憶するパターンに対して，この部分が必ず正になるよう $w_{j,i}$ を設定する  $\Rightarrow w_{j,i} = x_i^s x_j^s$  と設定  
( $x_i^s, x_j^s$  は記憶パターン $s$ のユニット値)




$w_{j,i} = 1$   
 $w_{j,i} = -1$ 
} と設定

記憶するデータが複数の場合は  
 $w_{j,i} = \sum_{p=1}^P x_i^s x_j^s$  とする

記憶できるパターンの数はユニット数  
 $n$  に対して  $\frac{n}{2 \log_2 n}$  個程度が限界

11/2/2023



## 出題予定の演習課題

- ホップフィールドモデルについて