

機械学習（8回目）

創域理工学部 情報計算科学科

桂田 浩一

1

10/19/2023

前回の復習

- ホップフィールドモデル

3

本日の内容

■ ボルツマンマシン

10/19/2023

4


ホップフィールドモデルの問題点

■ ホップフィールドモデルのユニット値更新式

$$x_i(t+1) = \begin{cases} 1 & (u_i(t) > 0) \\ x_i(t) & (u_i(t) = 0) \\ 0 & (u_i(t) < 0) \end{cases} \quad u_i(t) = \sum_{j=1}^n w_{j,i} x_j(t) - \theta_i$$

- x_i を更新すると $E = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n w_{j,i} x_i x_j + \sum_{i=1}^n \theta_i x_i$ が小さくなっていく

極小点に収束して最小点に行かない ⇒




10/19/2023


5

ランダム性の導入

■ $x_i = 1$ になる確率を $P(x_i = 1)$ と表したとき



ホップフィールドモデル



$$P(x_i = 1) = \frac{1}{1 + e^{-u_i/T}} \text{ とする}$$


$u_i > 0$ でも必ず $x_i(t+1) = 1$ とは限らない

10/19/2023

6

エネルギー関数の動き

■ x_i を更新していったときの E の動き



※一つの値には収束しない

※最小点を中心に確率的な状態の分布になる

10/19/2023


7

最終的な x_i の分布

- 状態を $x = (x_1, x_2, \dots, x_m)$ とするとき

$$P(x) = C e^{-E(x)/T} \quad (\text{ボルツマン分布})$$

$$\text{ただし } C = \frac{1}{\sum_x e^{-E(x)/T}} \left(\cong \frac{1}{\int e^{-E(x)/T} dE(x)} \right)$$



全てのとりうる (x_1, x_2, \dots, x_m) ,
つまり $(0, 0, \dots, 0)$ から $(1, 1, \dots, 1)$
までの全てのパターン

10/19/2023

8

ボルツマンマシン

- エネルギー関数の分布がボルツマン分布を取るニューラルネットワークを**ボルツマンマシン**と呼ぶ.

↓
十分に更新した時の状態が「分布」になるのなら、
最初から「**分布**」を学習しては？

↓
例えば「あ」と発話したときの音声波形とか

10/19/2023

9

今後の説明のための記号の変更

$$\begin{aligned} \blacksquare E &= -\frac{1}{2} \sum_i \sum_j w_{j,i} x_i x_j + \sum_i \theta_i x_i \\ &= -\sum_{(i,j)} w_{j,i} x_i x_j + \sum_i \theta_i x_i \quad ((i,j) \text{ は異なる } i, j \text{ の組合せ}) \end{aligned}$$

$$\blacksquare P(x) = C e^{-E(x)/T} \quad (C = \frac{1}{\sum_x e^{-E(x)/T}})$$

バイアス



ここで $T = 1$, $b_i = -\theta_i$, $\theta = (w, b)$, $z(\theta) = \frac{1}{C}$ と置き,
 $\Phi(x, \theta) = E$ とすると

$$P(x|\theta) = C e^{-E(x)/T} = \frac{1}{z(\theta)} e^{-\Phi(x, \theta)}$$

θ をパラメータと考え、 θ が与えられたときに
 x を取る確率を考える

10/19/2023

10

分布が正しく学習できているか？

- 最尤推定になっているかどうかで判断する

最尤推定：

データ集合 $X = \{x_1, x_2, \dots, x_N\}$ が与えられたとき,
 $\{x_1, x_2, \dots, x_N\}$ が未知の確率分布 $P_g(x)$ に従って
 生成されているとする。

$P_g(x)$ を知る方法はないので、適当な関数 $P(x|\theta)$
 を用意し、尤度関数 $L(\theta) = \prod_{n=1}^N P(x_n|\theta)$ が最大に
 なる θ のとき、 $P(x|\theta)$ は $P_g(x)$ に近いと考える。

データ集合 X から θ を推定する！！

10/19/2023

11

対数尤度

$$\ln L(\theta) = \sum_{n=1}^N \ln P(x_n | \theta)$$

$$P(x | \theta) = \frac{1}{z(\theta)} e^{-\Phi(x, \theta)} \text{ より}$$

$$\ln P(x_n | \theta) = -\Phi(x_n, \theta) - \ln z(\theta)$$

$$\ln L(\theta) = \sum_{n=1}^N (-\Phi(x_n, \theta) - \ln z(\theta))$$



これを最大にする θ のとき $P(x|\theta)$ と $P_g(x)$ は近い

このような θ を求めることが分布の学習になる
⇒勾配法で求める

10/19/2023

12

多層ニューラルネットとボルツマンマシンの比較

	学習の方針	学習後のネットワーク
多層ニューラルネット	誤差関数 E の最小化	入力に対して正しい出力を行う
ボルツマンマシン	対数尤度 $\ln L(\theta)$ の最大化	十分に更新した時のユニットの値 x_i の分布が正しい

多層ニューラルネットの重みの更新式 : $w \leftarrow w - \eta \frac{\partial E}{\partial w}$

ボルツマンマシンの重みの更新式 : $w \leftarrow w + \eta \frac{\partial \ln L(\theta)}{\partial w}$

ボルツマンマシンのバイアスの更新式 : $b \leftarrow b + \eta \frac{\partial \ln L(\theta)}{\partial b}$

10/19/2023

13

対数尤度関数の偏微分

$$\begin{aligned} \frac{\partial \ln L(\theta)}{\partial w_{j,i}} &= \frac{\partial \sum_{n=1}^N (-\Phi(x_n, \theta) - \ln z(\theta))}{\partial w_{j,i}} \\ &= \sum_{n=1}^N \left(-\frac{\partial \Phi(x_n, \theta)}{\partial w_{j,i}} - \frac{\partial \ln z(\theta)}{\partial w_{j,i}} \right) \end{aligned}$$

$$-\frac{\partial \Phi(x_n, \theta)}{\partial w_{j,i}} = \frac{\partial (\sum_{(i,j)} w_{j,i} x_i^n x_j^n + \sum_i b_i x_i^n)}{\partial w_{j,i}} = x_i^n x_j^n$$

10/19/2023

14

対数尤度関数の偏微分

$$-\frac{\partial \Phi(x_n, \theta)}{\partial w_{j,i}} = \frac{\partial (\sum_{(i,j)} w_{j,i} x_i^n x_j^n + \sum_i b_i x_i^n)}{\partial w_{j,i}} = x_i^n x_j^n$$

$$\begin{aligned} -\frac{\partial \ln z(\theta)}{\partial w_{j,i}} &= -\frac{1}{z(\theta)} \frac{\partial z(\theta)}{\partial w_{j,i}} = -\frac{1}{z(\theta)} \frac{\partial \sum_x e^{-\Phi(x, \theta)}}{\partial w_{j,i}} \\ &= -\frac{1}{z(\theta)} \sum_x \frac{\partial e^{-\Phi(x, \theta)}}{\partial w_{j,i}} = -\frac{1}{z(\theta)} \sum_x e^{-\Phi(x, \theta)} \frac{\partial (-\Phi(x, \theta))}{\partial w_{j,i}} \\ &= -\sum_x \frac{1}{z(\theta)} e^{-\Phi(x, \theta)} x_i x_j = -\sum_x P(x|\theta) x_i x_j \end{aligned}$$

全ての x を考えたときの $x_i x_j$ の期待値
($E_\theta[x_i x_j]$ と表す)

10/19/2023

15

対数尤度関数の偏微分

$$\begin{aligned}
 \frac{\partial \ln L(\theta)}{\partial w_{j,i}} &= \frac{\partial \sum_{n=1}^N (-\Phi(x_n, \theta) - \ln z(\theta))}{\partial w_{j,i}} \\
 &= \sum_{n=1}^N \left(-\frac{\partial \Phi(x_n, \theta)}{\partial w_{j,i}} - \frac{\partial \ln z(\theta)}{\partial w_{j,i}} \right) \\
 &= \sum_{n=1}^N (x_i^n x_j^n - E_{\theta}[x_i x_j]) \\
 &= \sum_{n=1}^N (x_i^n x_j^n) - N E_{\theta}[x_i x_j]
 \end{aligned}$$

10/19/2023

16

期待値の効率的な求め方

■ ギブスサンプリング

$$E_{\theta}[x_i x_j] = \sum_x P(x|\theta) x_i x_j$$


全ての x について加算するのは困難

⇒ x をランダムに $P(x|\theta)$ の確率で生成して平均値を求める。

($P(x_i = 1) = \frac{1}{1+e^{-u_i}}$ を使う.)

メリット：少ない数の x の生成で期待値の近似値が求まる

10/19/2023



出題予定の演習課題

- 対数尤度関数の偏微分