

## 線形回帰モデル (一般化最小二乗法, 最尤法)

### 1 一般化最小二乗法

次の線形回帰モデルを考える。

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon} \quad (1)$$

ここで,  $p < n$  として,

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{21} & \cdots & x_{p1} \\ 1 & x_{12} & x_{22} & \cdots & x_{p2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1n} & x_{2n} & \cdots & x_{pn} \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}, \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

とする。ただし,  $E(\boldsymbol{\varepsilon}) = \mathbf{0}$ ,  $V(\boldsymbol{\varepsilon}) = \sigma^2 \boldsymbol{\Omega}$  とし,  $\boldsymbol{\Omega}$  は  $n \times n$  の正定値対称行列とする。また, 前回の講義では,  $\boldsymbol{\varepsilon}$  に関して,

$$\text{条件 1: } E[\boldsymbol{\varepsilon}] = \mathbf{0}$$

$$\text{条件 2: } V[\boldsymbol{\varepsilon}] = \sigma^2 \mathbf{I}_n$$

を仮定したが, (1) 式の線形回帰モデルは, 条件 2 を満たすとは限らない。つまり, ガウス・マルコフの定理は, 条件 1 と 2 を仮定しているため, 最小二乗推定量

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$$

は最良線形不偏推定量になるとは限らない。そのため,  $\mathbf{I}_n \neq \boldsymbol{\Omega}$  の場合における最良線形不偏推定量を得ることを考える。

$\boldsymbol{\Omega}$  は正定値対称行列であることから, 適当な直交行列  $\mathbf{W}$  により次式のように対角化可能である。

$$\mathbf{W}^\top \boldsymbol{\Omega} \mathbf{W} = \boldsymbol{\Lambda}$$

ここで,  $\boldsymbol{\Lambda} = \text{diag}(\lambda_0, \lambda_1, \dots, \lambda_p)$  ( $\lambda_i > 0, i = 0, 1, \dots, p$ ) であることから, 次式が成り立つ。

$$\begin{aligned} \boldsymbol{\Omega} &= \mathbf{W} \mathbf{W}^\top \boldsymbol{\Omega} \mathbf{W} \mathbf{W}^\top \\ &= \mathbf{W} \boldsymbol{\Lambda} \mathbf{W}^\top \\ &= \mathbf{W} \boldsymbol{\Lambda}^{1/2} \boldsymbol{\Lambda}^{1/2} \mathbf{W}^\top \\ &= (\mathbf{W} \boldsymbol{\Lambda}^{1/2})(\mathbf{W} \boldsymbol{\Lambda}^{1/2})^\top \end{aligned}$$

$\mathbf{P} = (\mathbf{W} \boldsymbol{\Lambda}^{1/2})^{-1} = \boldsymbol{\Lambda}^{-1/2} \mathbf{W}^{-1}$  とすると,  $\mathbf{P} \boldsymbol{\Omega} \mathbf{P}^\top = \mathbf{I}_n$  となる。また,  $\mathbf{W}$  は直交行列であるので,  $\mathbf{W}^\top = \mathbf{W}^{-1}$  となる。したがって, 次式が成り立つ。

$$\begin{aligned} \mathbf{P}^\top &= ((\mathbf{W} \boldsymbol{\Lambda}^{1/2})^{-1})^\top \\ &= (\boldsymbol{\Lambda}^{-1/2} \mathbf{W}^{-1})^\top \\ &= (\mathbf{W}^{-1})^\top (\boldsymbol{\Lambda}^{-1/2})^\top \\ &= \mathbf{W} \boldsymbol{\Lambda}^{-1/2} \end{aligned}$$

$$\begin{aligned}
P^\top P &= W\Lambda^{-1/2}\Lambda^{-1/2}W^{-1} \\
&= W\Lambda^{-1}W^{-1} \\
&= (W\Lambda W^{-1})^{-1} \\
&= (W\Lambda W^\top)^{-1} \\
&= \Omega^{-1}
\end{aligned}$$

(1) 式の線形回帰モデルの両辺に左から  $P$  をかけると、次式が成り立つ。

$$PY = PX\beta + P\varepsilon \quad (2)$$

このとき、次式が成り立つため、(2) 式は、ガウス・マルコフの定理が成り立つための条件 1 と 2 を満たしている。

$$E[P\varepsilon] = PE[\varepsilon] = \mathbf{0}, \quad V[P\varepsilon] = PV[\varepsilon]P^\top = \sigma^2 P\Omega P^\top = \sigma^2 I_n$$

したがって、(2) 式の線形回帰モデルに対して、最小二乗法を用いることで、最良線形不偏推定量を得ることを考える。つまり、次式の関数の最小化問題を考える。

$$\begin{aligned}
f(\beta) &= \|P\varepsilon\|^2 \\
&= \|PY - PX\beta\|^2 \\
&= (PY - PX\beta)^\top (PY - PX\beta) \\
&= (Y - X\beta)^\top P^\top P (Y - X\beta) \\
&= (Y - X\beta)^\top \Omega^{-1} (Y - X\beta) \\
&= (Y^\top \Omega^{-1} - \beta^\top X^\top \Omega^{-1})(Y - X\beta) \\
&= Y^\top \Omega^{-1} Y - Y^\top \Omega^{-1} X\beta - \beta^\top X^\top \Omega^{-1} Y + \beta^\top X^\top \Omega^{-1} X\beta \\
&= Y^\top \Omega^{-1} Y - 2\beta^\top X^\top \Omega^{-1} Y + \beta^\top X^\top \Omega^{-1} X\beta \quad (\because \text{前回講義資料補足 1 と同様})
\end{aligned}$$

$\frac{\partial f(\beta)}{\partial \beta} = \mathbf{0}$  を解くと、

$$\begin{aligned}
\frac{\partial f(\beta)}{\partial \beta} &= -2X^\top \Omega^{-1} Y + 2X^\top \Omega^{-1} X\beta \\
&\left( \because \frac{\partial \beta^\top X^\top \Omega^{-1} Y}{\partial \beta} = X^\top \Omega^{-1} Y, \quad \frac{\partial \beta^\top X^\top \Omega^{-1} X\beta}{\partial \beta} = 2X^\top \Omega^{-1} X\beta \right)
\end{aligned}$$

であることから、次式を得る。

$$X^\top \Omega^{-1} X\beta = X^\top \Omega^{-1} Y \quad (3)$$

この連立方程式 (3) の解を求める方法を一般化最小二乗法という。 $X^\top \Omega^{-1} X$  が正則であれば、一般化最小二乗推定量は次式で与えられる。

$$\hat{\beta} = (X^\top \Omega^{-1} X)^{-1} X^\top \Omega^{-1} Y \quad (4)$$

## 2 最尤法

線形回帰モデルにおける最小二乗法と最尤法の間関係を考える。多変量確率変数  $Y = (Y_1, Y_2, \dots, Y_n)^\top$  の関数を  $f(y|\theta)$  ( $\theta \in \Theta$ ) で定義する。ここで、 $f(y|\theta)$  は、 $Y$  が

連続型であれば確率密度関数, 離散型であれば確率関数である。 $\boldsymbol{\theta} = (\theta_1, \theta_2, \dots, \theta_p)^\top$  は,  $p \times 1$  の未知のパラメータベクトルであり,  $\Theta$  はパラメータ空間である。

$\mathbf{Y}$  の観測値  $\mathbf{y} = (y_1, y_2, \dots, y_n)^\top$  が得られたとき,  $\boldsymbol{\theta}$  の関数とみなした  $\boldsymbol{\theta}$  の尤度関数を次のように定義する。

$$L(\boldsymbol{\theta}|\mathbf{y}) = f(\mathbf{y}|\boldsymbol{\theta}) \quad (5)$$

確率 (密度) 関数  $f(\mathbf{y}|\boldsymbol{\theta})$  は,  $\boldsymbol{\theta}$  が与えられたとき, どのような  $\mathbf{y}$  が得られやすいかを示す関数である。一方, 尤度関数  $L(\boldsymbol{\theta}|\mathbf{y})$  は,  $\mathbf{y}$  が与えられたとき, それが出現しやすいパラメータの値を示す関数である。

尤度関数  $L(\boldsymbol{\theta}|\mathbf{y})$  を最大化することにより, 未知パラメータ  $\boldsymbol{\theta}$  を推定する方法を**最尤法**という。最尤法により得られる  $\boldsymbol{\theta}$  の推定量

$$\hat{\boldsymbol{\theta}} = \hat{\boldsymbol{\theta}}(\mathbf{Y}) = \arg \max_{\boldsymbol{\theta} \in \Theta} L(\boldsymbol{\theta}|\mathbf{Y})$$

を**最尤推定量**といい,  $\mathbf{Y}$  を  $\mathbf{y}$  で置き換えた  $\hat{\boldsymbol{\theta}} = \hat{\boldsymbol{\theta}}(\mathbf{y})$  を**最尤推定値**という。したがって, 最尤法では, 何かしらの統計モデルを仮定し, 得られた  $\mathbf{y}$  から尤度関数  $L(\boldsymbol{\theta}|\mathbf{y})$  を最大にする未知パラメータ  $\boldsymbol{\theta}$  の推定問題を考えている。

最尤推定量を求める場合, (5) 式の尤度関数を対数変換した**対数尤度関数**  $l(\boldsymbol{\theta}|\mathbf{y}) = \log L(\boldsymbol{\theta}|\mathbf{y})$  の最大化

$$\hat{\boldsymbol{\theta}} = \hat{\boldsymbol{\theta}}(\mathbf{Y}) = \arg \max_{\boldsymbol{\theta} \in \Theta} l(\boldsymbol{\theta}|\mathbf{Y})$$

を考えることが多い。最尤推定量  $\hat{\boldsymbol{\theta}}$  は, 次式から得られる方程式の解として求めることが一般的である。

$$\frac{\partial l(\boldsymbol{\theta}|\mathbf{Y})}{\partial \boldsymbol{\theta}} = \begin{pmatrix} \frac{\partial l(\boldsymbol{\theta}|\mathbf{Y})}{\partial \theta_1} \\ \frac{\partial l(\boldsymbol{\theta}|\mathbf{Y})}{\partial \theta_2} \\ \vdots \\ \frac{\partial l(\boldsymbol{\theta}|\mathbf{Y})}{\partial \theta_p} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix} = \mathbf{0}$$

この方程式を**尤度方程式**という。

### 3 線形回帰モデルの最尤推定問題

次の線形モデルの最尤推定問題を考える。

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n) \quad (6)$$

ここで,  $p < n$  として,

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{21} & \cdots & x_{p1} \\ 1 & x_{12} & x_{22} & \cdots & x_{p2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1n} & x_{2n} & \cdots & x_{pn} \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}, \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

とする。 $\varepsilon \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$  であることから,  $\mathbf{Y} \sim N(\mathbf{X}\boldsymbol{\beta}, \sigma^2 \mathbf{I}_n)$  となる (補足 2 参照)。

### 補足 2

多変量確率変数  $\mathbf{x} = (x_1, x_2, \dots, x_n)^\top$  の積率母関数は,  $\boldsymbol{\theta}^\top = (\theta_1, \theta_2, \dots, \theta_n)$  とするとき, 次式で定義される。

$$\phi_{\mathbf{x}}(\boldsymbol{\theta}) = E[\exp(\boldsymbol{\theta}^\top \mathbf{x})]$$

$\phi_{\mathbf{x}}(\boldsymbol{\theta})$  を適当回数微分することにより, 任意の次数のモーメントを求めることができる。つまり,  $\sum_{i=1}^n k_i = k$  とすれば, 次式が成り立つ。

$$\left[ \frac{\partial^k \phi_{\mathbf{x}}(\boldsymbol{\theta})}{\partial \theta_1^{k_1} \partial \theta_2^{k_2} \dots \partial \theta_n^{k_n}} \right] = E \left[ x_1^{k_1} x_2^{k_2} \dots x_n^{k_n} \right]$$

$\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  のとき,  $\mathbf{x}$  の確率密度関数は次式となる。

$$f(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{n/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left[ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right]$$

多変量正規分布  $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  の積率母関数は次式によって与えられる。

$$\phi_{\mathbf{x}}(\boldsymbol{\theta}) = \exp \left( \boldsymbol{\theta}^\top \boldsymbol{\mu} + \frac{1}{2} \boldsymbol{\theta}^\top \boldsymbol{\Sigma} \boldsymbol{\theta} \right)$$

$\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  のとき,  $\mathbf{y} = \mathbf{C}\mathbf{x} + \boldsymbol{\lambda} \sim N(\mathbf{C}\boldsymbol{\mu} + \boldsymbol{\lambda}, \mathbf{C}^\top \boldsymbol{\Sigma} \mathbf{C})$  となることを示す。ただし,  $\mathbf{C}$  は  $p \times n$  行列,  $\text{rank}(\mathbf{C}) = p$ ,  $\boldsymbol{\lambda}$  は  $p$  次元定数ベクトルである。 $\mathbf{y}$  の積率母関数が  $N(\mathbf{C}\boldsymbol{\mu} + \boldsymbol{\lambda}, \mathbf{C}^\top \boldsymbol{\Sigma} \mathbf{C})$  の積率母関数であることを示せばよい。

$$\begin{aligned} \phi_{\mathbf{y}}(\boldsymbol{\theta}) &= E \left[ \exp \left( \boldsymbol{\theta}^\top (\mathbf{C}\mathbf{x} + \boldsymbol{\lambda}) \right) \right] \\ &= E \left[ \exp \left( \boldsymbol{\theta}^\top \mathbf{C}\mathbf{x} + \boldsymbol{\theta}^\top \boldsymbol{\lambda} \right) \right] \\ &= \exp \left( \boldsymbol{\theta}^\top \boldsymbol{\lambda} \right) E \left[ \exp \left( \boldsymbol{\theta}^\top \mathbf{C}\mathbf{x} \right) \right] \\ &= \exp \left( \boldsymbol{\theta}^\top \boldsymbol{\lambda} \right) \phi_{\mathbf{x}}(\mathbf{C}^\top \boldsymbol{\theta}) \\ &= \exp \left( \boldsymbol{\theta}^\top \boldsymbol{\lambda} \right) \exp \left( \boldsymbol{\theta}^\top \mathbf{C}\boldsymbol{\mu} + \frac{1}{2} \boldsymbol{\theta}^\top \mathbf{C}\boldsymbol{\Sigma} \mathbf{C}^\top \boldsymbol{\theta} \right) \\ &= \exp \left( \boldsymbol{\theta}^\top (\mathbf{C}\boldsymbol{\mu} + \boldsymbol{\lambda}) + \frac{1}{2} \boldsymbol{\theta}^\top \mathbf{C}\boldsymbol{\Sigma} \mathbf{C}^\top \boldsymbol{\theta} \right) \end{aligned}$$

以上より,  $\mathbf{x} \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  のとき,  $\mathbf{y} = \mathbf{C}\mathbf{x} + \boldsymbol{\lambda} \sim N(\mathbf{C}\boldsymbol{\mu} + \boldsymbol{\lambda}, \mathbf{C}^\top \boldsymbol{\Sigma} \mathbf{C})$  となる。

このとき, 尤度関数は次式となる。

$$\begin{aligned} L(\boldsymbol{\beta}, \sigma^2 | \mathbf{Y}) &= \frac{1}{(2\pi)^{n/2} |\sigma^2 \mathbf{I}_n|^{1/2}} \exp \left[ -\frac{1}{2} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top (\sigma^2 \mathbf{I}_n)^{-1} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) \right] \\ &= \frac{1}{(2\pi\sigma^2)^{n/2}} \exp \left[ -\frac{1}{2\sigma^2} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) \right] \end{aligned}$$

したがって、対数尤度関数は次式となる。

$$\begin{aligned}
 l(\boldsymbol{\beta}, \sigma^2 | \mathbf{Y}) &= \log L(\boldsymbol{\beta}, \sigma^2 | \mathbf{Y}) \\
 &= \log \left[ \frac{1}{(2\pi\sigma^2)^{n/2}} \exp \left[ -\frac{1}{2\sigma^2} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) \right] \right] \\
 &= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})
 \end{aligned} \tag{7}$$

$\boldsymbol{\theta} = (\beta_0, \beta_1, \dots, \beta_p, \sigma^2)^\top$  とし、次式のように対数尤度関数  $l(\boldsymbol{\beta}, \sigma^2 | \mathbf{Y}) = l(\boldsymbol{\theta} | \mathbf{Y})$  の最大化を考える。

$$\hat{\boldsymbol{\theta}} = \hat{\boldsymbol{\theta}}(\mathbf{Y}) = \arg \max_{\boldsymbol{\theta} \in \Theta} l(\boldsymbol{\theta} | \mathbf{Y})$$

(7) 式より、対数尤度関数を  $\boldsymbol{\beta}$  に関して最大化することと、 $(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})$  を  $\boldsymbol{\beta}$  に関して最小化することは同値であることがわかる。つまり、最小二乗法は、 $(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})$  を  $\boldsymbol{\beta}$  に関して最小化する方法であることから、 $\boldsymbol{\beta}$  の最尤推定量と最小二乗推定量は一致することがわかる。実際に、 $\boldsymbol{\beta}$  と  $\sigma^2$  の最尤推定量を求める。

$$\frac{\partial l(\boldsymbol{\beta}, \sigma^2 | \mathbf{Y})}{\partial \boldsymbol{\beta}} = -\frac{1}{\sigma^2} (-\mathbf{X}^\top \mathbf{Y} + \mathbf{X}^\top \mathbf{X} \boldsymbol{\beta}) \quad (\equiv \mathbf{0}) \tag{8}$$

$$\frac{\partial l(\boldsymbol{\beta}, \sigma^2 | \mathbf{Y})}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) \quad (\equiv 0) \tag{9}$$

(8) 式より、次式を得る。

$$\mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} = \mathbf{X}^\top \mathbf{Y}$$

したがって、 $\mathbf{X}^\top \mathbf{X}$  が正則であれば、 $\boldsymbol{\beta}$  の最尤推定量は次式となる。

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$$

以上のことから、 $\boldsymbol{\beta}$  の最尤推定量と最小二乗推定量は一致する。

一方、(9) 式より、次式を得る。

$$\begin{aligned}
 \frac{n}{2\sigma^2} &= \frac{1}{2(\sigma^2)^2} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}) \\
 \Leftrightarrow \sigma^2 &= \frac{1}{n} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})
 \end{aligned}$$

したがって、 $\sigma^2$  の最尤推定量は次式となる。

$$\hat{\sigma}^2 = \frac{1}{n} (\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})^\top (\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})$$

## 問 2

$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \boldsymbol{\varepsilon} \sim N(\mathbf{0}, \sigma^2 \mathbf{I}_n)$ ,  $\text{rank}(\mathbf{X}) = p + 1$ ,  $\hat{\sigma}^2 = \frac{1}{n}(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})^\top (\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}})$ ,  $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$  とする。

- (1) 残差ベクトル  $\mathbf{e}$  を  $\mathbf{e} = \mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}$  として定義する。 $\mathbf{H} = \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top$  としたとき、次式が成り立つことを示せ。

$$\mathbf{e} = (\mathbf{I}_n - \mathbf{H})\boldsymbol{\varepsilon}$$

- (2)  $E[\mathbf{e}^\top \mathbf{e}]$  を求めよ。  
 (3)  $\hat{\sigma}^2$  は  $\sigma^2$  の不偏推定量であるかどうかを確認せよ。

## 問 3

次の線形モデルの最尤推定問題を考える。

$$\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim N(\mathbf{0}, \sigma^2 \boldsymbol{\Omega})$$

ここで,  $p < n$  として,

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ Y_2 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{21} & \cdots & x_{p1} \\ 1 & x_{12} & x_{22} & \cdots & x_{p2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{1n} & x_{2n} & \cdots & x_{pn} \end{pmatrix}, \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_p \end{pmatrix}, \quad \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix},$$

とする。このとき,  $\boldsymbol{\beta}$  の最尤推定量を求めよ。

## 参考文献

- [1] 佐和隆光. (2020). 回帰分析 (新装版). 朝倉書店.  
 [2] 森裕一, 黒田正博, 足立浩平. (2017). 最小二乗法・交互最小二乗法. 共立出版.